剧透检测系统准确率测试报告

《球状闪电》评论剧透识别评估

CommentMask / SpoilerShield

2026 年 4 月 23 日

目录

1 测试概述

本报告针对书籍《球状闪电》（book_id = 9，共 2422 段），对剧透检测系统进行系统性准确率评估。测试数据由 Claude claude-sonnet-4-6 批量生成，检测由本系统 RAG + LLM 流水线执行。

2 测试数据集

类别	预期数量	实际生成
剧透评论	300	292
非剧透评论	700	670
合计	1000	962
生成失败（跳过）	—	38

表 1: 测试集构成

评论长度控制在 20–50 字（中文），从书籍前半部分（1211 段）随机抽取段落生成。

3 检测流水线

3.1 RAG 召回策略

1. **语义向量检索**（top-k = 5）：使用 `all-MiniLM-L6-v2` 模型对评论编码，与段落预计算 embedding 做余弦相似度排序，最低准入阈值 similarity ≥ 0.45。

2. **关键词频次检索**（top-k = 3）：统计中文字符在段落中的出现频次，取频次最高的 3 段作为补充召回。

3. **合并去重**：两路结果合并，按 `para_index` 去重。

4. **未来段落过滤**：仅保留 `para_index > current_para_index` 的段落作为剧透上下文。

5. **上下文长度控制**：若未来段落总字数超过 1200 字，则对每段提取关键词密度最高的 120 字片段（Snippet）传入 LLM。

6. **无上下文回退**：若两路召回均未通过准入阈值，告知 LLM「未发现相关后续内容，请仅根据常识判断」。

3.2 LLM 判断

召回内容连同当前段落、评论文本，以 JSON 格式提示词发送至 `claude-sonnet-4-6`，要求返回：

- `is_spoiler`：布尔值
- `confidence`：0.0–1.0 置信度
- `reason`：判断依据

置信度阈值 ≥ 0.7 时标记为 `HIDDEN`（剧透）或 `PUBLIC`（公开），否则标记为 `PENDING_REVIEW`（待审核）。

4 检测结果

4.1 数据有效性

项目	数量
总评论数	1000
有效检测	813
跳过（生成失败）	38
检测失败（网络）	147
检测失败（其他）	2

表 2: 检测有效性统计

共 187 条未获得有效结果，其中 147 条为网络连接错误（`Connection error`），38 条为评论生成阶段失败，均已从指标统计中排除。

4.2 混淆矩阵

	预测：剧透	预测：非剧透
实际：剧透	TP = 264	FN = 8
实际：非剧透	FP = 2	TN = 539

表 3: 混淆矩阵（813 条有效样本）

指标	数值
Accuracy（准确率）	98.8%
Precision（精确率）	99.2%
Recall（召回率）	97.1%
F1 Score	98.1%

表 4: 剧透检测性能指标

4.3 性能指标

5 结果分析

5.1 优势

- **极低误报率**（FP = 2，精确率 99.2%）：系统几乎不会将正常评论误标为剧透，用户体验友好。
- **高召回率**（97.1%）：仅有 8 条剧透评论漏报，剧透防护效果显著。
- **F1 = 98.1%**：精确率与召回率均衡，整体性能优秀。

5.2 不足与改进方向

- **网络稳定性**：147 条检测因网络错误失败（14.7%），建议增加重试机制（exponential backoff）。
- **漏报分析**（FN = 8）：8 条剧透被判为非剧透，可能原因是该评论内容与后续段落语义距离较远，RAG 未召回相关上下文，LLM 仅凭常识判断时保守估计。可考虑扩大 top-k 或降低准入阈值。
- **测试集偏差**：评论由 Claude 生成，与真实用户评论风格存在分布差异，建议补充真实标注数据进行二次评估。

6 结论

在 813 条有效样本上，系统达到 **98.8% 准确率**、**98.1% F1**，剧透检测效果优异，适合在阅读平台中作为自动审核的主要手段。主要瓶颈在于网络连接稳定性，与模型判断能力无关。